지능형 엣지 서비스 실행 가속을 위한 SW/인프라기술

2021.12.09.

GS-Engine 프레임워크 리더

최현화(hyunwha@etri.re.kr)

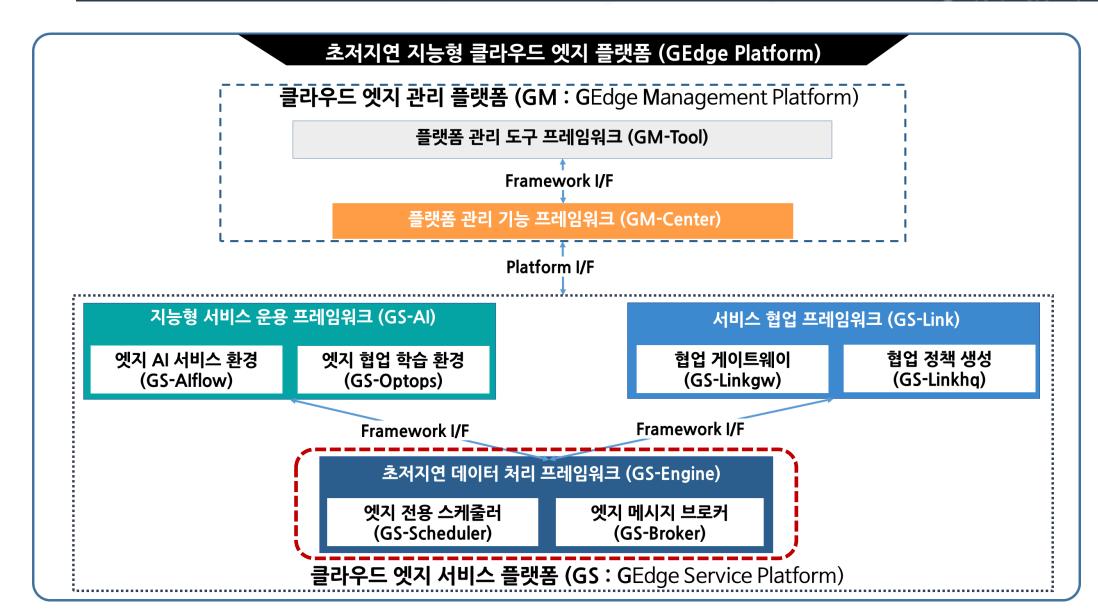
"GEdge Platform" 은 클라우드 중심의 엣지 컴퓨팅 플랫폼을 제공하기 위한 핵심 SW 기술 개발 커뮤니티 및 개발 결과물의 코드명입니다.

- Developer-Friendly

GEdge Platform Community 3rd Conference (GEdge Platform v2.0 Release) -



이번 발표의 기술적 포지셔닝



Contents

- 지능형 엣지 서비스(AI)
- GSE API Server
- | 기술 데모 및 향후 계획

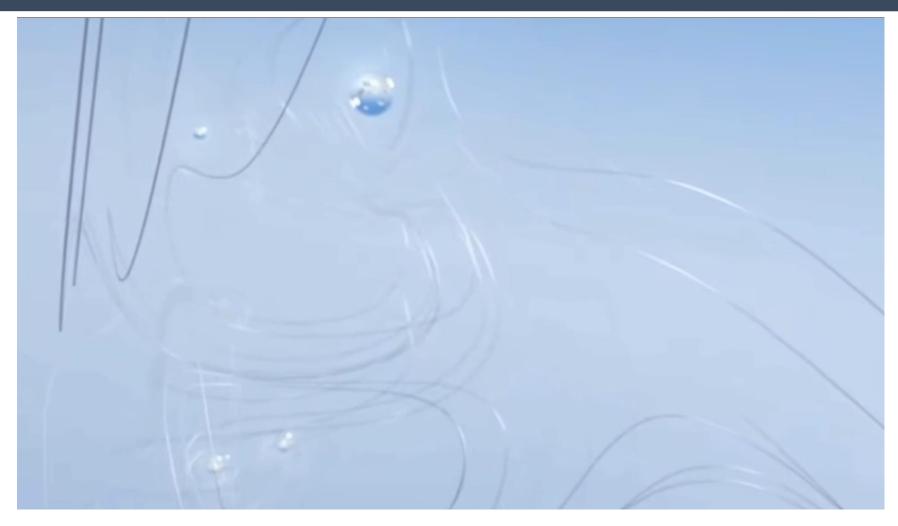
지능형 엣지 서비스(AI)





지능형 엣지 서비스의 영역은?





Al can do Everything

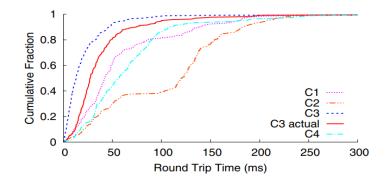
지능형 엣지 서비스 지원 방법



지능형 엣지 서비스 성능 비교

Public Cloud

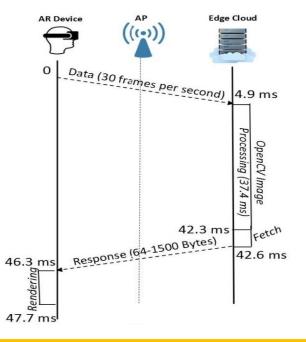




The latency of services deployed by cloud providers is over 100ms

Ref: CloudCmp: Comparing Public Cloud Providers (ACM IMC 2010)

Edge Cloud

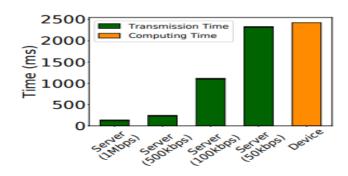


The latency of services has 50ms

Ref: Scalability and Performance Evaluation of Edge Cloud Systems for Latency Constrained Application (ACM/IEEE SEC 2018)

Smart Device





It takes more than 2s to execute the model on the resource-limited Raspberry PI

Ref: Edge AI: On-Demand Accelerating Deep Neural Network Inference via Edge Computing(IEEE transactions on wireless communications. 2019)





CPU 자원 선점 (1)



- 지연 시간 민감형 서비스
 - (Target 응용 특징) CPU intensive / IO intensive
 - (성능 강화 방안) Context switching/CPU affinity

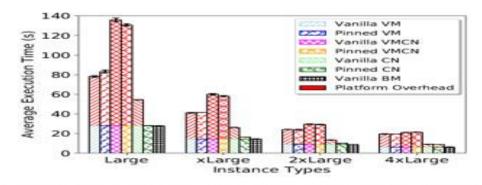
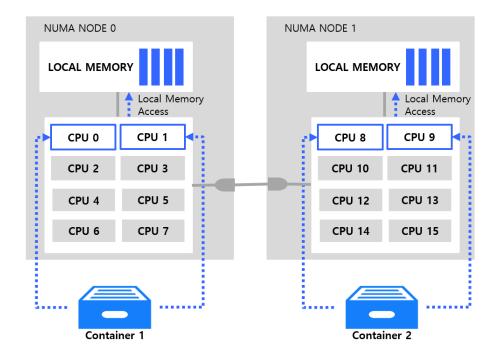


Fig. 3: Comparing execution time of FFmpeg on different execution platforms under varying number of CPU cores.



Fig. 5: Comparing mean response time (aka execution time) of 1,000 web processes on different execution platforms (WordPress evaluation)

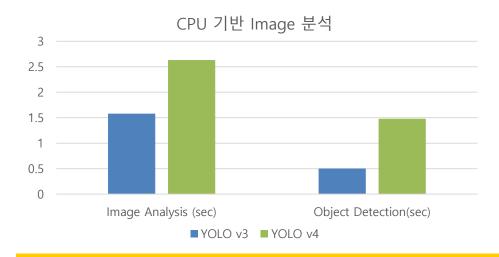


Ref: The Art of CPU-Pinning: Evaluating and Improving the Performance of Virtualization and Containerization Platforms (2006)

CPU 자원 선점 (2)



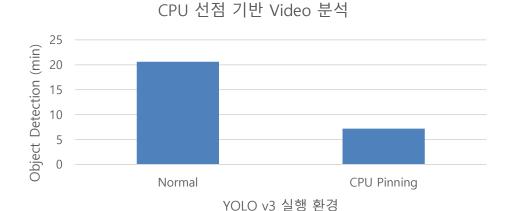
- CPU 기반 성능 실험
 - 2020년 : CPU 자원 선점 기반으로 동영상 인코딩 (**52% 성능 향상)**
 - 지능형 서비스의 성능 실험: YOLO 기반 객체 인식(v1~v5)
 - : 실시간 동영상(스트리밍) 분석 지원 **(300% 성능 향상)**
 - : (1 FPS) 쿠팡 물류센터 화재/침입탐지형 서비스는 CPU만 분석 가능



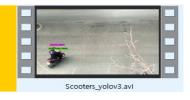
- YOLO v3 우수: v3(107 layer), v4(162 layer) => Precision은 거의 동일, v3 41% 빠름
- 이미지 분석 시간에서 Object detection 은 33% 차지



https://pjreddie.com/darknet/yolo/



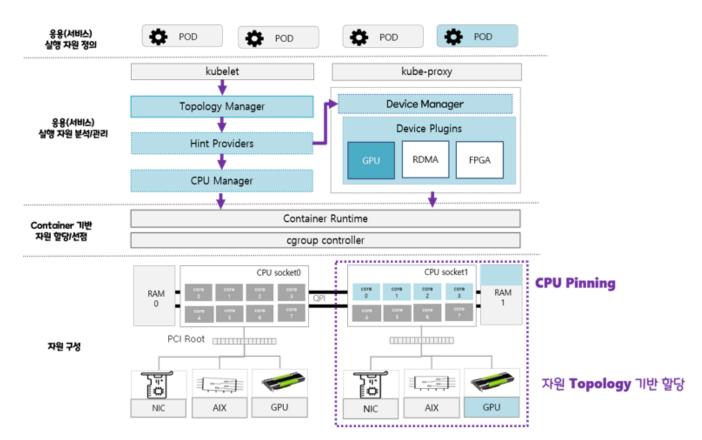
- YOLO v3 기반 Scooter.mp4 분석 => HD(1280*720), 14sec(30.481KB)
- 300% 성능 향상 (1 FPS 분석)
 - => Sliding Window 분석 속도



토폴로지 인지형 자원 선점 (1)



- 초저지연 지능형 서비스 지원
 - 자원간 Affinity / Data copy 최소화
 - CCTV와 같은 스트리밍 분석 (CPU/GPU tasks)



Evaluating the Performance of Deep Learning Inference Service on Edge Platform Jae-Geun Cha Artificial Intellipence Research Lab. ETRI

Daejeon, South Korea jgrhametri re.kr Doe Won Kim Artificial Intelligence Research Lab. ETRI

Sun Wook Kim rtificial Intelligence Research Lab. ETRI

Seung-Hyun Yun
Technology Support Team
SoftonNet
Seoul, South Korea

Abstract—Deep learning inference requires tremendous amount of computation and typically is offloaded the cloud for state at the edge of the Internet closest to the mobile devices or remover, has been considered as sow computing paradigm. We have studied the performance of the deep neural network (DNN) internets service based on different configurations of resources internet service based on different configurations of resources a real-world edge service on continerization platform. An edge service is manded AEN, an application with various DNN internets. The edge service has both CPU-friendly and GPU-latency of the edge service (or unadayses reveal interesting fundings about running the DNN inference service on the container-based execution polaritorm. (a) The battery of DNS container-based execution polaritorm. (a) The battery of DNS container-based execution polaritor. (b) Prinning CPUs can reduce the latency of the edge service, (c) In order to improve the performance of an edge service, (c) In order to improve the performance of an edge service, (c) In order to improve the CPUs bothlessed; shared by recovered into CPUs, CPUS and NCC.

services require an end-to-end latency of less than tens of milliseconds. Meanwhile, DNN inference on the resource-limited device takes more than 2 s [7]. Clearly, we can know that offlood is important for applications with DNN inference.

Recently edge computing which processes and stores due of the edge of the Indies of the Indies

computing fields. One of major challenges in edge computing a realizing deep learning at the edge.

First, researchers designed the DNN model with

Vehicle Plate Analysis



SW requirement

- GPU driver
- CUDA 10.1+
- cuDNN 7.6 +
- Pvthon 3.7 +
- Python-pip 20.2.x +
- Virtualenv 20.0.x +
- TensorRT 6.0
- TensorFlow 2.1

토폴로지 인지형 자원 선점 (2)



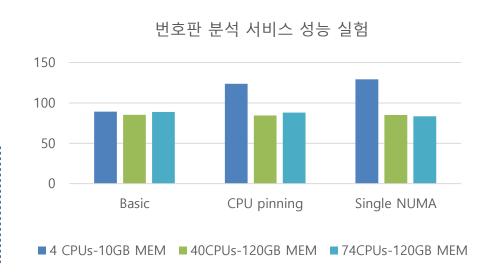
• 자동차 번호판 인식

- Data: FHD(1920*1080) 709MB (total frames: 107,836)

- Model: SSD_MobileNet v2, Lenet-prelu, DeepSORT

성능 실험 결과 (1 container, 1 노드)

	4 CPUs-10GB MEM	40CPUs-120GB MEM	74CPUs-120GB MEM
Basic	89.1	85.24	88.72
CPU pinning	123.71	84.42	88.06
Single NUMA	129.17	84.94	83.47
Single Helvirt	123.17	0 1.5 1	03.17



성능 실험 결과 (2 container, 멀티 노드)

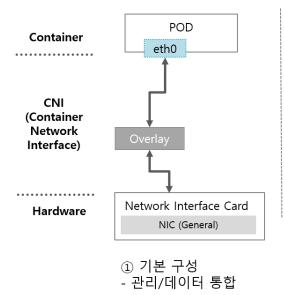
	1Node-1Pod	1Node-2Pods	2Nodes-2Pods	2Nodes-2Pod(/w CPU Pinning)	2Nodes-2Pod(148CPUs)	2Nodes-2Pods(240GB)
analysis time (msec)	88.72	86.57	97.16	97.03	98.9	97.16

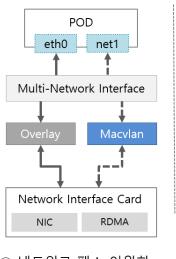
- 엣지 서비스 성능은 CPU 작업과 GPU 작업 성능에 의존 (CPU:GPU = 58: 42)
- CPU를 선점시키는 것은 엣지 서비스 성능 향상(3%)
- → 대용량 데이터 입력, 다중 모델(데이터 이동)/이종 자원 → PCle 공유자원 bottleneck

하드웨어 가속 기반 네트워크 이원화

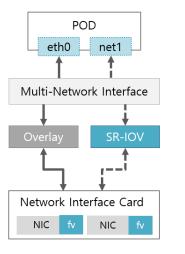


- 응용간 데이터 전송 가속
 - 클러스터 관리 네트워크: Flannel
 - Communication-intensive 서비스 가속
 - : 데이터 전송 패스 이원화 : 다중 NIC 컨테이너 지원
 - : 데이터 전송 하드웨어 가속 (SR-IOV)
 - : RDMA 지원

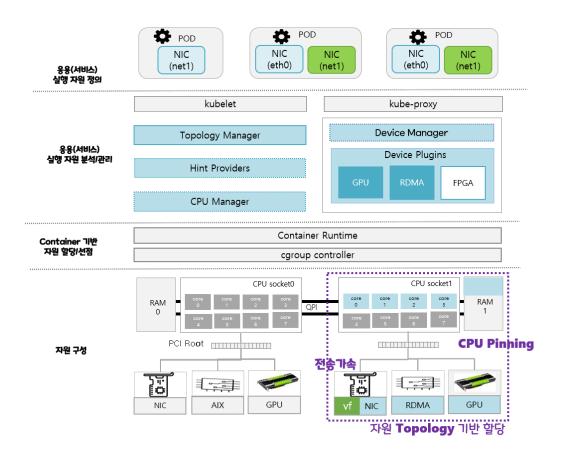




② 네트워크 패스 이원화 - 관리/데이터 분리



③ 하드웨어 가속 기술 지원 - 관리/데이터분리&가속



지능형 서비스 가속 실행 (1)



- 지능형 서비스의 자원할당
 - CPU : hyper-thread 단위로 할당 (Integer 단위로 요청/할당)
 - 시스템 운영에 필요한 CPU 사용 보장 (kubelet의 config 설정)

```
kubeReserved:
cpu: 500m
```

- GPU-CPU 자원간 토폴로지 인지 자원 할당: Best-effort

263590560Ki

110

```
Addresses:
  InternalIP: 129.254.202.130
  Hostname:
               gedgeworker01
Capacity:
                      80
  cpu:
  ephemeral-storage:
                      427237720Ki
  hugepages-1Gi:
  hugepages - 2Mi:
                      263692960Ki
  memory:
  pods:
                      110
Allocatable:
                      80
  cpu:
  ephemeral-storage:
                      393742282101
  nugepages - 1G1:
```

hugepages-2Mi:

memory:

pods:

```
Addresses:
  InternalIP: 129.254.202.133
 Hostname:
               gedgeworker02
Capacity:
  cpu:
  ephemeral-storage:
                      427237720Ki
  hugepages - 1Gi:
  hugepages - 2Mi:
                       263692948Ki
  memory:
  pods:
                       110
Allocatable:
                       79500m
  cpu:
                       393742282101
  ephemeral-storage:
 inugepages-16i:
  hugepages - 2Mi:
                       263590548Ki
  memory:
                       110
  pods:
```

```
서비스 정의
```

```
service:
 name: app2,
 containers: [ {
    image: k8s.gcr.io/echoserver:1.10,
    ports: [ {
       containerPort: 8080,
       protocol: TCP,
      externalPort: 80
     }],
    resources: {
     requests: {
      cpu: 200m,
      memory: 500Mi },
      acceleration: {
      toploygyAware: true,
      compute: [
         {"GPU": 1}
      communication: SRIOV
 }]
```

지능형 서비스 가속 실행 (2)



- 지능형 서비스의 데이터 전송 패스 가속
 - 이종의 데이터 전송 가속 패스 구성 지원

Network Plugin

: Flannel, Multus, SRIOV, RDMA

- 네트워크 구성에 따른 성능 시험 도구 제공

>>> SR-IOV 지원 《《

Network ConfigMap

```
03 sriov configmap.yaml
1 apiVersion: v1
2 kind: ConfigMap
3 ∨ metadata:
      name: sriovdp-config
      namespace: kube-system
6 v data:
7 ∨ config.json: |
8 ~
9 ~
            "resourceList": [
10 ~
                    "resourceName": "intel sriov netdevice",
11
                    "selectors": {
12 ~
                        "vendors": ["8086"],
13
                        "devices": ["37cd"],
15
                        "drivers": ["iavf"]
18
19
```

Network CRD

```
! 06 sriov-static.yaml
 1 apiVersion: "k8s.cni.cncf.io/v1"
     kind: NetworkAttachmentDefinition
     metadata:
       name: sriov-net1
       annotations:
         k8s.v1.cni.cncf.io/resourceName: intel.com/intel sriov netdevice
     spec:
       config: '{
9
       "type": "sriov",
       "cniVersion": "0.3.1",
10
       "name": "sriov-network",
11
12
       "ipam": {
13
         "type": "static"
14
```

Service Definition

Multus 초기화

SR-IOV 초기화

싛라우드 엣지 SW 플랫폼 시험환경

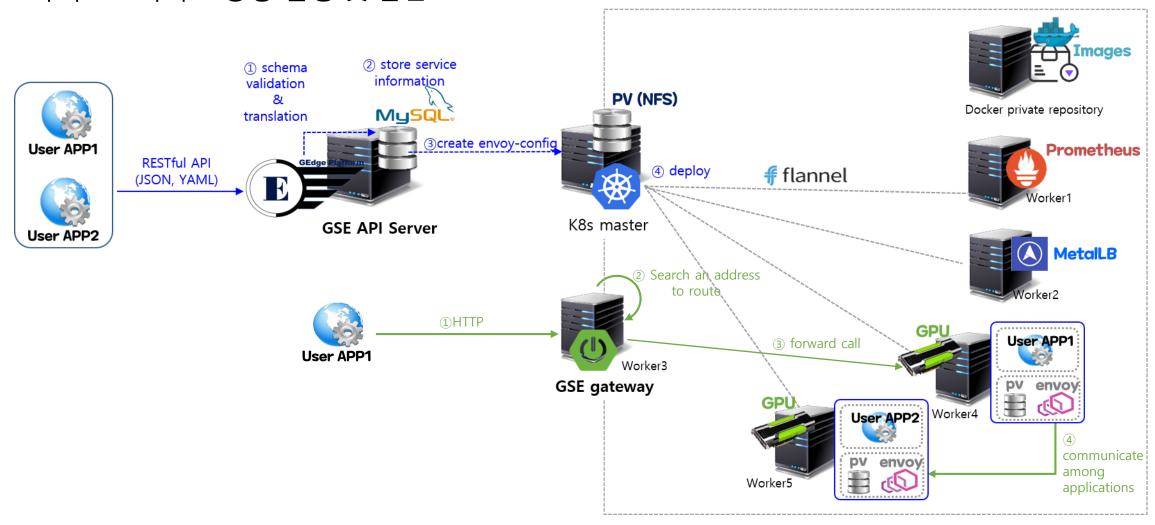
NIC 설정 삭제

```
07 test-pods > ! iperf-server-sriov-1.yml
      apiVersion: v1
      kind: Pod
  3 ∨ metadata:
        name: sriov-server-1
        labels:
          name: sriov-server-1
        annotations:
 8 i~
          k8s.v1.cni.cncf.io/networks: '[
 9
                  { "name": "sriov-net1",
                    "ips": [ "10.10.2.60/24" ]
 10
 11
 12
 13 ~
 14
        nodeName: gedgew01
 15
        containers:
 16 ~
        - name: sriov-server-1
          image: cisdocker/iperf3:2020
 17
          command: ["iperf3", "-s"]
 18
 19 ~
        resources
            requests:
 20 V
 21
             intel.com/intel sriov netdevice: '1'
 22 ~
            limits:
 23
              intel.com/intel sriov netdevice: '1'
```

마이크로서비스 응용 지원 (1)



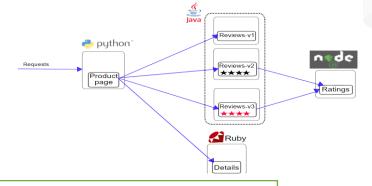
마이크로서비스 응용 실행 및 접근



마이크로서비스 응용 지원 (2)



- 마이크로서비스 응용 정의
 - Template: 여러 마이크로서비스 응용 정의에서 공통 사용 지원 (실행 공유: 미지원)
 - ServiceMesh: 다른 버전의 응용을 하나의 서비스로 정의 지원, 사용자 접근 응용 지정



```
Template
"template": {
  "name": "hw-app",
  "service": {
    "containers": [
      "image": "129.254.202.122:5000/hw app:v2.0",
      "ports": [{
        "containerPort": 8080,
        "protocol": "TCP",
        "externalPort": 80
      "resources": {
        "requests": {
          "cpu": "200m",
           "memory": "500Mi"
```

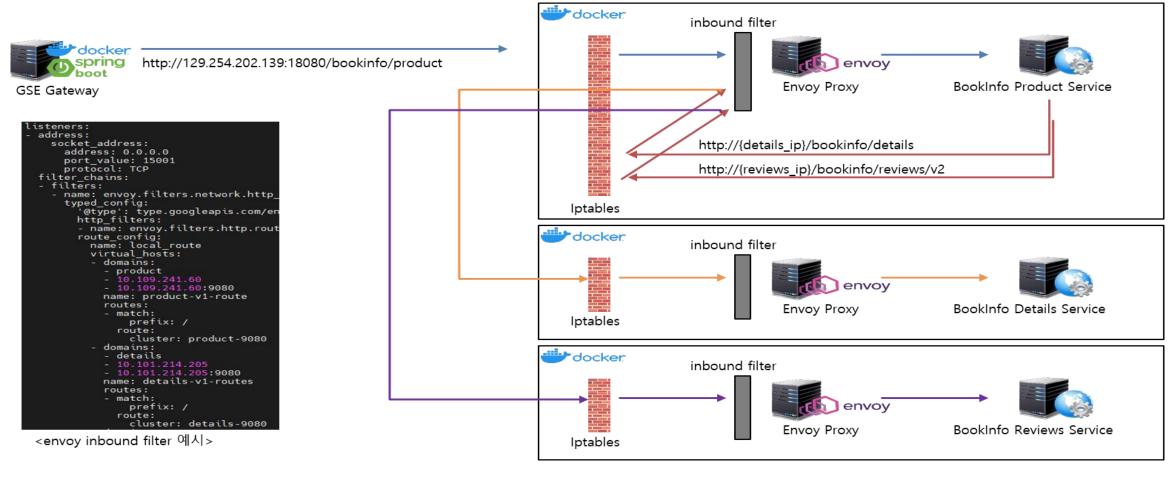
```
ServiceMesh
 "serviceMesh": {
   "name": "service-mesh2".
   "services": [
     "name": "product",
     "template": "bookinfo-product",
     "labels": {
      "version": "v1"
      "externalAccess": true
     "name": "details",
     "template": "bookinfo-details",
     "labels": {
      "version": "v1"
```

```
"serviceRoutes": [
   "name": "product-v1-route",
   "match": [ {
     "uri": {
      "prefix": "/ }
   "destination": {
     "host": "product",
     "subset": "v1"}
   "name": "details-v1-routes".
   "match": [ {
     "uri": {
      "prefix": "/"}
   "destination": {
     "host": "details"
]}
```

마이크로서비스 응용 지원 (3)



- 마이크로서비스 응용 연계
 - Init container를 이용한 iptables 설정





기술 데모 및 향후 계획



1 기술 데모





향후 계획



실행환경

- Monolithic 지원
- Service Schema
- Scaling(Out/In)
- 다중 메트릭 지원 (Resource, Custom)

Infra

- 자원선점(CPU)
- 다중 네트워크 지원
- 네트워크 패스이원화

실행환경

- 지능형서비스 성능분석
- Microservices 지원
- 서비스 가속 환경 지원
- 오토스케일링 확장

Infra

- 자원 선점(CPU/GPU)가속 자원 지(GPU)
- RDMA 지원

실행환경

- Function 지원
- 서비스 가속 환경확장
- Scaling(over Edge)
- 이벤트 관리기

Infra

- 자원 선점 (HW)
- 네트워크 필터링
- RDMA 기능 확장
- 네트워크 라우팅 패스 구성

실행환경

- 다중 실행환경 최적화
- 이벤트 기반 서비스 실행기

Infra

- 자원 선점확장(HW)
- 네트워크 라우팅패스 확장 및 구동
- 5G 모바일 엣지 네트워크 연동









감사합니다.

http://gedge-platform.github.io



GS-Engine 프레임워크 리더 최현화(hyunwha@etri.re.kr)

Welcome to GEdge Platform

An Open Cloud Edge SW Plaform to enable Intelligent Edge Service

GEdge Platform will lead Cloud-Edge Collaboration